

한국어 주식 댓글의 주가 예측 적중 분류

댓글 텍스트만으로 '적중하는 예측'을 가려낼 수 있는가 (토스증권 TSLA·NVDA 데이터를 4 Class 분류기에 적용)

RESEARCH QUESTION

댓글로 주가를 맞힌 사람들 중, 진짜 '실력자'가 있는가?

진짜 실력자가 있다면 그들의 댓글을 학습해 믿을 만한 예측을 가려낼 수 있지 않을까?

주가를 예측하는 모델이 아니라 '적중한 사람의 언어'를 텍스트로 분류하는 문제 제안

주식 시장에 '실력'은 존재하는가, 아니면 전부 운인가?

막연한 호기심을 텍스트만으로 검증 가능한 가설로 재정의한다

출발점이 된 호기심

- 1** 댓글로 주가를 맞힌 사람은 분명 있다
토스증권 피드에는 '적중' 댓글이 실제로 존재한다.
- 2** 그런데 그건 실력일까, 운일까?
한두 번의 적중은 운과 실력이 섞여 있다.
- 3** 실력이라면 — '말투'를 학습할 수 있지 않을까?
적중한 사람의 글쓰기가 통계적으로 구별된다면, 모델로 가려낼 수 있다.

● → 이 호기심을 '검증 가능한 질문'으로 바꾸는 것이 첫 과제다.

RQ1 댓글로 적중한 사람 중 진짜 실력자가 있는가?

적중이 '운'과 구별되는가

RQ2 (있다면) 그 실력자를 모델로 감지할 수 있는가?

적중 댓글(C2·C3) 감지 분류기로 조작화


핵심 재정의

'주가를 예측하는 모델'이 아니다

예상 적중한 사람의 글(구체적 근거·변동 예측 날짜 및 목표가·차분한 어조)이 그렇지 않은 글과 구별되는가를 오직 텍스트로 복원하는 분류 문제다

주가는 '정답' 생성에만, 모델 입력은 오직 텍스트

순환논리·데이터 누수 공격을 설계 단계에서 원천 차단한다



누수 방어 모델 입력 = 텍스트 (+ 주주 여부) 뿐 — 주가·미래 정보는 0. 적중 판정은 LLM이 아니라 주가로 사후 계산하므로, '과거 글로 미래를 맞힌다'는 순환논리가 성립하지 않는다.

Class 0

예측 없음

잡담·리액션·광고

Class 1

예측 실패

방향 예측했으나 빗나감

Class 2

방향 적중

방향은 맞음(날짜 미명시/빗나감)

Class 3

날짜+방향 적중

우연 확률 최저 → 분리 시 '언어 학습' 강한 근거

최근 변동성이 가장 컸던 6개월, 토스증권 23.6만 댓글

직접 크롤링·가명처리한 실제 데이터

236,003

총 수집 댓글

TSLA 122,171 + NVDA 113,832

2

분석 종목

TSLA · NVDA (미국 고변동주)

6개월

수집 기간

2025.10 – 2026.05

63,040

고유 작성자

두 종목 모두 4,966명

수집·전처리 설계

- '제목 + 본문'을 결합한 텍스트를 단일 분석 단위로 사용
- 수집 즉시 HMAC 가명처리 — 동일 작성자 구분은 유지(일관성 분석 대비)
- 이미지·URL/링크는 텍스트 분석에서 제외(노이즈 처리)
- 8개 컬럼 구성 · 작성일은 초 단위까지 보존(예측/리액션 시점 판정에 필수)

왜 이 종목·기간인가 (참신성)

변동성이 클 때의 예측을 분석한다는 문제 정의에 맞춰, 고변동 종목·기간을 의도적으로 선정했다.


변동성 ↔ 댓글량 상관 **TSLA $r=0.45$ · NVDA $r=0.33$** ($p<.001$)

→ 변동이 클수록 댓글이 몰린다 = '예측 vs 리액션'이 섞이는 구간이라는 신호.


댓글은 어떤 '가격 사건' 위에서 쓰였는가

다중일 누적 기준($h=5$, $k=1.0$)으로 상승·하락 변동 사건 구간을 음영 표시

TSLA — 주가 추이 · 변동 사건



NVDA — 주가 추이 · 변동 사건



So What 변동 사건 주변에 댓글이 집중된다. 이 '가격 사건'이 라벨(2절)의 기준이자, '오르기 전 예측'과 '오른 뒤 리액션'을 가르는 출발점이다. (색상 관례: 빨강=상승 · 파랑=하락)


라벨링 전 단계의 핵심 파라미터 확정

변동 판정선 Sweep · 길이 분포로 max_length · 유저 메타 파악

변동 판정선 Sweep (h=5 · k=1.0 확정)


변동 판정선 ($\mu h \pm \sigma \sqrt{h}$)의 Threshold Sweep (판정폭 계수 k, 누적기간 길이 h)

판정폭 계수 k를 1.5로 하면 유의미한 변동 사건 수가 급감하여 고수 라벨 거의 안 생기므로 k=1.0 채택
변동 지속율(높을수록 진짜 사건)이 높으면서 유의미한 변동일 비율도 너무 적지 않은 h=5 채택




변동 지속율(↑)이 높으면서 사건 수도 충분한 지점으로 선택 · seed=42

댓글 토큰 수 분포 (max_length=512)



유저 메타데이터 (주주 66.1% · 뱃지 3.9%)




어떤 '연속 구간'을 학습·평가로 떼어냈는가

상승·하락이 함께 들어가도록 방향 균형 표집 · 종목 간 교차 + user-disjoint로 누수 차단

학습 구간 — TSLA (녹색 점선)

tsla_train — TSLA 추출 구간 · 학습셋 (Fold A: TSLA→NVDA)


fig1(빨강=상승·파랑=하락 변동사건) 위에 추출 구간(녹색 점선) 표시 · 댓글 20,206건 · 2025-11-07~2025-12-04



평가 구간 — NVDA (녹색 점선)

nvda_eval — NVDA 추출 구간 · 평가셋 (Fold A: TSLA→NVDA)

fig1(빨강=상승·파랑=하락 변동사건) 위에 추출 구간(녹색 점선) 표시 · 댓글 9,084건 · 2026-04-22~2026-05-07



단방향 교차 (TSLA 학습 → NVDA 평가) 학습 20,206건 → 평가 9,084건. 종목을 분리해 시간·사건 누수를 구조적으로 차단하고, 평가 종목에서 학습 작성자 277명을 제거(user-disjoint)했다. 역방향(NVDA→TSLA)은 후속 과제.

LLM으로 예측 정보 추출, 적중 여부는 직접 계산

한국 투자 문화 주입 + 댓글 직전 48h 가격 맥락으로 '예측 vs 리액션' 분리

1 도메인 그라운드

빨강 = 상승 / 파랑 = 하락 (한국 관례, 미국과 반대)를 프롬프트에 명시. 떡상·존버·익절·물타기 등 용어집 + 예측/리액션 few-shot 고정 주입.

2 가격 맥락 주입

댓글 작성 직전 48h 가격 흐름을 함께 입력 → '이미 오른 뒤 리액션'과 '오르기 전 예측'을 구분. 미래 구간은 절대 주지 않는다.

3 적중은 결정적 계산

적중 여부는 LLM이 아니라 우리 코드가 주가로 계산 ($W_{dir} \cdot W_{hit}$, 다중일 누적). 누수·재현성 방어.

LLM 출력 스키마

시점관계(예측/리액션)

예측_방향(상승/하락/없음)

예측_날짜

확신도 0~1

근거_유형

Class0_사유

검증 통과

qwen3.5 · JSON 100% · 에러 0 · 색상 관례 정확 · 예측/리액션 구분 · 날짜 환산("연말" → 12-31). 확신도 컷오프 $\tau=0.5$ 확정.

모델 벤치마크

도메인 일치·한국어 표준·금융 도메인을 같은 시드(42)로 비교해 macro-F1 최고 모델 채택

후보 모델 — 임의 선택 배제

KcELECTRA 댓글 도메인 — 구어체·신조어·오타자에 강함 (주력 후보)

KLUE-RoBERTa 한국어 NLU 표준 — ‘표준보다 나은가’의 레퍼런스

KR-FinBERT 금융 도메인 — 정형 텍스트 위주 (ablation 성격)

+ ModernBERT-ko 2024년 최신 인코더 — 후보로 검토(최신성 반영)

입력 설계 텍스트 앞에 [주주]/[비주주] 특수토큰 prepend. 뱃지는 입력에서 제외(‘뱃지→고수’ shortcut 방지).

불균형 처리 class weight·focal loss + macro-F1 기준 early stopping (정확도 아님).

입력 → 인코더 → 4-way 분류

[CLS] [주주] 본문 ... [SEP]



한국어 인코더 (fine-tune)



[CLS] 표현 → 4-way head



C0 · C1 · C2 · C3

동일 시드 42 · 동일 분할 — 모델 간 비교를 같은 조건에서 수행

학습 설정

Class-weighted Focal Loss로 어려운 소수 클래스에 집중, macro-F1으로 모델 평가

CONFIG

EPOCHS 6 · BATCH 32 · LR 1e-5 · MAX_LEN 512 · SEED 42 · CLASSES 4 (C0-C3)

LOSS

Class-weighted Focal Loss

$$\mathcal{L} = \frac{1}{N} \sum_i (1 - p_{t,i})^\gamma \cdot w_{y_i} \cdot (-\log p_{t,i})$$

- 교차 엔트로피 $-\log p_t$ — 다중 클래스 분류의 기본 항
- Class weight $\sqrt{(N/C \cdot n_c)}$ — 빈도 역가중($\sqrt{\text{완화}}$)으로 불균형 보정
- Focal ($1-p_t$) — 쉬운 샘플 down-weight($\gamma=2$) → 어려운 샘플 집중

METRIC

Macro-F₁ (주 지표)

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

macro = 클래스별 F1의 단순 평균 (C0-C3)

- 용도 모델 선택 & early stopping 기준
- 근거 불균형 데이터 → 소수 클래스까지 동등 반영
- 보조 accuracy — 전체 정확도 참고용

01 모델 & 입력

전이학습 한국어 PLM fine-tuning
벤치마크 KcELECTRA·KLUE·RoBERTa·KR-FinBERT
특수토큰 TemplateProcessing → [CLS]/[SEP]
커스텀 토큰 [주주]/[비주주] prepend

02 학습 최적화

스케줄 LR warmup 0.1 + weight decay 0.01
Mixed precision fp16 (A100)
Dynamic padding DataCollatorWithPadding
Early stopping patience = 3

03 분할 & 검증

Stratified split 라벨 비율 유지
누수 차단 학습셋에서 val 15% 분리
베이스라인 다수클래스 · TF-IDF+LogReg
교차 일반화 TSLA → NVDA (단방향)


텍스트에 '적중 신호'는 있다

단방향(TSLA 학습 → NVDA 평가) · 원본 라벨 · 평가셋은 자연 분포 유지

모델 / 베이스라인	macro-F1	Acc	C0-F1	C1-F1	C2-F1	C3-F1
단방향 · KLUE-RoBERTa	0.389	0.810	0.925	0.217	0.184	0.232
단방향 · KR-FinBERT	0.343	0.802	0.920	0.211	0.175	0.069
단방향 · KcELECTRA	0.342	0.813	0.930	0.223	0.214	0.000
베이스라인 · TF-IDF+LogReg	0.323	0.757	0.882	0.123	0.116	0.170
베이스라인 · 다수클래스	0.231	0.860	0.925	0.000	0.000	0.000

예측없음 C0 / 예측실패 C1 / 방향적중 C2 / 날짜적중 C3


macro-F1 비교



러닝커브 학습량↑에 따라 C2-F1이 계속 우상향 → '신호 부재'가 아니라 데이터 부족. '운이다' 단정 불가, 라벨 확대가 답.

희소 클래스를 보강해 재학습 시도

2차 라벨로 적중 표본 C2, C3을 643→969건(+51%) 보강 후 재학습



보강 결과

모델	macro-F1	Acc	C2-F1	C3-F1
KLUE-RoBERTa	0.350	0.825	0.107	0.127
KR-FinBERT	0.349	0.819	0.156	0.069
KcELECTRA	0.329	0.820	0.148	0.000
TF-IDF+LR	0.323	0.758	0.130	0.133

보강 후 macro-F1은 1단계만큼 오르지 않았음. 이는 enriched 학습셋 ↔ 자연분포 테스트의 분포 불일치(+ best epoch 오선택)라고 판단. 따라서 최종 성능 보고는 1단계 기준으로 한다. 분포 정합·평가 설계 개선은 후속 과제.

줄 세우면 1등은 나온다! 그러나 고수 후보를 빗겨간다

유저 실력 순위 Top 10 (147명 중)

Top 10 = 고수후보 5명 + 대조군 5명 (사전 선정 집단의 우위 없음)

순위	닉네임_ID	그룹	예측 / 적중	적중률 (T/N)	실력점수
1	0c75e17bc0	대조군	17/8	47% (0/53)	1.721
2	6fbb50809f	고수후보	12/6	50% (40/57)	1.615
3	fd63412dbc	대조군	17/5	29% (38/0)	1.557
4	e5cfd92202	대조군	6/3	50% (-/50)	1.308
5	c009fbb778	대조군	37/4	11% (15/0)	1.141
6	33f2a077c0	고수후보	201/22	11% (11/-)	1.128
7	77710d12d5	고수후보	74/26	35% (-/35)	0.956
8	7d95a21f3a	대조군	41/6	15% (8/27)	0.897
9	156d3fa10c	고수후보	15/2	13% (13/-)	0.869
10	efae43b158	고수후보	15/2	13% (-/13)	0.867

우리의 '1등'이 운이었던 진짜 이유, 그리고 다음 질문

표본 편향 — 우리가 본 건 '단타 구간의 고수'뿐

고수후보를 '고변동 구간에서 활발히 활동한 유저'로 한정해 결과, 단기 매매 성향에 표본이 치우쳤다

변동이 본격화되기 이전 시점의 예측자(중장기 관점)는 관찰되지 못했다

이 표본 편향이 '적중 = 운'이라는 결론에 기여했을 수 있다

따라서 '몇 개월 전 예측자가 진짜 고수'라는 가설을 증명하는 것을 후속 연구로 삼는다

● 우리의 기여

누수 0 설계 위에서 '운 vs 실력'을 단일 글·날짜·사람·
벡터·2차 held-out 5개 각도로 정직하게 검증한 재현
가능한 파이프라인

● 비용 · 시간 제약

라벨링 비용 초과로 부분 데이터, 단방향만 수행
역방향(NVDA→TSLA) 교차와 사람 k 검수는 도구까지
준비된 후속 단계

● 다음 연구

- 변동 '선행' 구간 기준으로 예측자 표집 후 검증
- 사용자 일관성 필터링

